

Rubrica de Avaliação do Projeto Final

Aprendizagem de Máquina (pós-graduação)

Prof. Leandro Maciel Almeida

2026.1

A nota final do projeto é calculada pela soma dos critérios abaixo, cada um avaliado em quatro níveis de desempenho. O peso total é 100%, decomposto a partir do esquema 40% (clareza do modelo) + 50% (rigor experimental) + 10% (apresentação) já publicado no documento da disciplina.

Escala de níveis

- **Insuficiente** (0 a 0,40): item ausente, incorreto ou sem evidências.
- **Básico** (0,50 a 0,70): item presente porém superficial; faltam justificativas ou evidências robustas.
- **Bom** (0,75 a 0,90): item completo, com decisões justificadas e evidências adequadas.
- **Excelente** (0,95 a 1,00): item completo, com análise profunda, comparações pareadas e narrativa clara.

Critério	Peso	Insuficiente	Básico	Bom	Excelente
Clareza do modelo (Etapa 1) - subtotal 40%					
Etapa 1: motivação e intuição do modelo	5%	Sem motivação ou intuição confusa.	Motivação presente porém genérica.	Motivação clara, intuição bem ilustrada.	Motivação contextualizada na literatura recente; intuição convincente.
Etapa 1: arquitetura e formulação matemática	15%	Arquitetura ausente ou incorreta.	Diagrama presente, formulação incompleta.	Arquitetura e formulação completas e coerentes.	Arquitetura, formulação e justificativas alinhadas; relação entre blocos clara.
Etapa 1: complexidade e posicionamento na literatura SOTA	10%	Sem análise de complexidade nem comparações.	Complexidade citada de forma rasa; poucas referências.	Complexidade $O(n,p)$ e pico de memória documentados; literatura coerente.	Complexidade quantificada nos experimentos; posicionamento detalhado em 2023-2026.
Model card detalhado (todas as 11 seções preenchidas)	10%	Model card ausente ou apenas com placeholders.	Apenas metade das seções; análise quantitativa ausente.	Todas as seções preenchidas; intervalo de confiança nas métricas.	Seções 3 (fatores), 7 (análise quantitativa) e 9 (avisos e recomendações) com narrativa rica e evidências.
Rigor experimental (Etapa 2) - subtotal 50%					
Etapa 2: seleção e justificativa dos 30 datasets (10+10+10)	5%	Datasets ausentes ou não estratificados.	Lista incompleta ou sem regime balanceado.	30 datasets com regime correto e tabela com OpenML task ID.	30 datasets com cobertura adequada de classes binária/multiclasse e regime de missing.
Etapa 2: baselines + AutoGluon executados conforme exigência	8%	Baselines ou AutoGluon ausentes.	Apenas baselines, sem AutoGluon ou apenas um preset.	Baselines (LightGBM, CatBoost, XGBoost) e AutoGluon default + extreme 4h.	Tudo acima, com checagem de sanidade e custo computacional documentado.
Etapa 2: busca de hiperparâmetros do modelo do grupo (Optuna)	10%	Sem busca ou busca arbitrária.	Busca rasa, sem análise de convergência.	Busca via Optuna documentada, com curvas de validação.	Busca refinada com pruning e análise de sensibilidade dos hiperparâmetros.
Etapa 2: análise estatística (Friedman, Nemenyi e Bayesian com ROPE)	12%	Sem teste estatístico ou apenas médias.	Friedman aplicado, sem post-hoc nem análise Bayesiana.	Friedman + Nemenyi (CD diagram) + Bayesian signed-rank com ROPE.	Todos os testes acima com narrativa interpretativa por par e por regime.
Etapa 2: análise por regime (quatro eixos)	10%	Resultados apenas agregados.	Apenas um ou dois eixos analisados.	Quatro eixos (tamanho, n classes, prop. categorica, missing) com gráficos.	Análise por regime articulada com a teoria do modelo, identificando vencedores e perdedores.
Etapa 2: custo vs desempenho com AutoGluon como referência	5%	Sem análise de custo.	Custo total citado, sem comparação.	Scatter tempo total vs AUC com os 15 sistemas.	Discussão de fronteira de Pareto e recomendações práticas para o cliente fictício.
Apresentação oral - subtotal 10%					
Apresentação: cumprimento do tempo (20 min, 10+10)	4%	Excede 25 minutos ou termina abaixo de 15 minutos.	Cumprir 20 min total mas com etapas desbalanceadas (mais de 12 minutos em uma).	Cumprir 20 min com Etapa 1 e Etapa 2 dentro de 10 +/- 1 min cada.	Cumprir 20 min com transições fluidas e equilíbrio entre etapas.
Apresentação: divisão clara entre integrantes	3%	Apenas um integrante apresenta.	Distribuição desequilibrada.	Todos os integrantes apresentam de forma clara.	Distribuição planejada, com transições nomeadas e responsabilidades evidentes.
Apresentação: qualidade visual (gráficos, tabelas, slides)	3%	Slides confusos ou ilegíveis.	Slides limpos mas sem leitura interpretativa.	Slides claros, gráficos auto-explicativos.	Slides polidos, com legibilidade a distância e leitura precisa de cada figura.

Tabela 1: Rubrica do Projeto Final (pós-graduação). Pesos somam 100%, decompondo o esquema $40 + 50 + 10$ do PDF da disciplina.

Notas operacionais

- A pontuação em cada critério resulta da multiplicação do peso pelo nível atingido (0,40; 0,70; 0,90; 1,00, conforme escala).
- Para os critérios de busca de hiperparâmetros e análise estatística, ausência de evidências quantitativas (curvas, tabelas, p-valores) penaliza um nível inteiro.
- Reprodutibilidade do repositório (notebooks executando de ponta a ponta com poucos comandos) e pre-requisito para o nível Excelente em qualquer critério que dependa de evidência experimental.
- Violação do split (uso do conjunto de teste antes da avaliação final) zera os critérios de Etapa 2 que dependem de teste honesto.