

Projeto Final - Aprendizagem de Máquina (pós)

Modelo: [NOME DO MODELO]

Grupo: [INTEGRANTES]

2026.1

Apresentação

Etapa 1 - Fundamentação teórica do modelo (10 minutos)

- Motivação e intuição
- Arquitetura e formulação
- Complexidade e hiperparâmetros
- Posicionamento na literatura tabular SOTA

Etapa 2 - Estudo experimental (10 minutos)

- Metodologia (30 datasets do TabArena, baselines + AutoGluon)
- Resultados, ranking, diagrama de diferença crítica
- Comparação Bayesiana com ROPE e análise por regime
- Custo vs desempenho e conclusões

Etapa 1: motivação do problema

- Classificação tabular ainda é dominada por modelos baseados em árvores.
- Novos paradigmas (foundation models, MLPs modernas, RNAs recursivas) prometem ganhos.
- **Pergunta:** em quais regimes o modelo X é competitivo?

Comparação sistemática e respostas baseadas em 30 datasets do TabArena-v0.1.

Etapa 1: intuição do modelo

- Ideia central em uma frase: [...].
- Diferença em relação aos baselines: [...].
- Garantia teórica ou heurística que sustenta a ideia: [...].

[diagrama conceitual]

Etapa 1: arquitetura

[diagrama de blocos da arquitetura]

Componentes principais: [bloco A], [bloco B], [bloco C].

Etapa 1: formulação matemática

- Função de perda: [...]
- Regularização: [...]
- Etapa de inferência: [...]

Atalhos notacionais e variaveis na formulação podem ser detalhados no relatório.

Etapa 1: complexidade computacional

Operacao	Tempo	Memória	Observação
Treino	$O(\dots)$	$O(\dots)$	[crescimento com n e p]
Inferência	$O(\dots)$	$O(\dots)$	[latência típica]

Pico de memória observado: [valor em GB] em datasets do regime grande.

Etapa 1: hiperparâmetros principais

Hiperparâmetro	Faixa de busca (Optuna)	Efeito esperado
[hp1]	[...]	[trade-off viés-variância]
[hp2]	[...]	[efeito sobre tempo de treino]
[hp3]	[...]	[...]

Etapa 1: posicionamento na literatura tabular SOTA

- 2023: [trabalho A].
- 2024: [trabalho B] (NeurIPS) e [trabalho C].
- 2025: [trabalho D] (ICLR), [trabalho E] e o modelo X.
- 2026: trabalhos correlatos em desenvolvimento.

O modelo X se diferencia por: [diferenciador 1], [diferenciador 2].

Etapa 1: limites teóricos do modelo

- Restrições de tamanho (n maximo, p maximo).
- Suposições sobre os dados (IID, ausência de ruído estrutural, etc.).
- Casos onde o modelo não se aplica ou degrada de forma previsível.

Etapa 2: metodologia experimental

- **Datasets:** 30 do TabArena-v0.1 (10 + 10 + 10 por regime de tamanho).
- **Split:** 70/30 estratificado por classe, seed fixa.
- **Busca:** Optuna (TPE) com validação cruzada no treino.
- **Métricas:** AUC OvO, ACC, G-Mean, Cross-Entropy, tempo total.
- **Concorrentes:** 9 modelos atribuíveis + 3 baselines + AutoGluon default e extreme 4h.

Etapa 2: resultados gerais

Sistema	AUC OvO	Ranking médio	Tempo (s)
Modelo do grupo	0,xx $\pm$ 0,0xx	x,x	xxx
LightGBM TD	0,xx $\pm$ 0,0xx	x,x	xxx
CatBoost TD	0,xx $\pm$ 0,0xx	x,x	xxx
XGBoost TD	0,xx $\pm$ 0,0xx	x,x	xxx
AutoGluon default	0,xx $\pm$ 0,0xx	x,x	xxx
AutoGluon extreme 4h	0,xx $\pm$ 0,0xx	x,x	xxx

Posição do modelo do grupo no ranking: [x de 15].

Etapa 2: ranking médio e diagrama de diferença crítica

[diagrama de diferença crítica - autorank, post-hoc Nemenyi]
Friedman $p = [\text{valor}]$; grupos estatisticamente equivalentes em destaque.

Etapa 2: comparação Bayesiana (signed-rank com ROPE)

Comparação	p(modelo X melhor)	p(equivalente)	p(pior)
Modelo X vs LightGBM TD	0,xx	0,xx	0,xx
Modelo X vs CatBoost TD	0,xx	0,xx	0,xx
Modelo X vs XGBoost TD	0,xx	0,xx	0,xx
Modelo X vs AutoGluon default	0,xx	0,xx	0,xx
Modelo X vs AutoGluon extreme	0,xx	0,xx	0,xx

ROPE = 0,01 em AUC OvO; gerado por baycomp.

Etapa 2: análise por regime (tamanho e número de classes)

[tamanho: pequeno, médio, grande]

[n classes: binário vs multiclasse]

Etapa 2: análise por regime (categoricas e missing)

[proporção categorica: baixa vs alta]

[missing: com NaN vs sem NaN]

Etapa 2: custo vs desempenho

[scatter: tempo total (eixo x) por AUC OvO media (eixo y) com os 15 sistemas]

AutoGluon extreme define o teto prático; baselines TD, o piso barato.

Etapa 2: onde o modelo brilha e onde fracassa

- Brilha em: [tipo de regime] (exemplo: [dataset], $\text{delta} = +0,0xx$).
- Fracassa em: [tipo de regime] (exemplo: [dataset], $\text{delta} = -0,0xx$).
- Provavel causa: [propriedade do dado ou limite teórico identificado].

Etapa 2: comparação honesta com AutoGluon

- Quanto AutoML "compra" em termos de AUC OvO? Delta médio: $[0, 0xx]$.
- Custo extra de AutoGluon extreme vs modelo X: [fator de tempo].
- Quando o ganho de AutoML é relevante na prática? [resposta baseada nos regimes].

- Posição do modelo: [resumo em uma frase].
- Pontos fortes: [...]
- Limites: [restrições de n , p , regime, dependência de pesos pré-treinados].
- Próximos passos: [coletar mais regimes, calibracao, integracao com pipelines AutoML].

Perguntas?

Repositório: [link]

Contato: [emails dos integrantes]

Referências principais: [3 a 5 itens]